

Année universitaire	2025-2026		
Filière	Informatique	Année	M2 Data Eng et Data Science
Matière	Outils ETL		
Enseignant	Haytham Elghazel		
Intitulé TD/TP :	TP2 : Projet Data Engineering - Passage d'un ETL classique à une architecture ELT moderne		
Rendu	Rendu sur Moodle		

1. Objectif général


L'objectif de ce mini projet est de refondre notre pipeline de traitement de données initialement conçu en ETL avec Talend en une architecture ELT moderne, plus proche des pratiques industrielles actuelles. En d'autres termes, ce projet vous permettra de passer d'une logique outil-centrée (ETL) à une logique data-centrée (ELT). C'est aujourd'hui l'approche privilégiée dans les architectures data modernes.

Vous travaillerez à partir de fichiers CSV, que vous devrez ingérer, transformer et modéliser afin de produire un data warehouse en schéma en étoile, en suivant une architecture en médaillon :

- Bronze (données brutes)
- Silver (données nettoyées)
- Gold (données analytiques)

2. Contexte initial (ETL classique)

Dans le projet sur lequel on a travaillé jusqu'à la, les données sont traitées selon une approche **ETL** avec **Talend** :



Les transformations sont effectuées dans Talend, avant le chargement dans la base de données. Les limites principales de cette approche sont que les transformations sont faites hors BD (en Java) et la faible scalabilité sur des gros volumes de données.

3. Nouvelle approche demandée : ELT

Dans ce projet, vous devez adopter une approche **ELT**. Dans ELT, la base de données devient le moteur de transformation.



a. Architecture en médaille

Votre data warehouse devra être organisé selon les trois niveaux suivants, matérialisés par des schémas ou préfixes de tables distincts.

Couche Bronze : les Données brutes

L'objectif de la couche **BRONZE** est de conserver les données telles qu'ingérées. Vous utiliserez **Airbyte** pour charger les fichiers CSV dans la base de données. Les données doivent être chargées sans transformation métier, telles quelles.

- Source : fichiers CSV (dossier local ou distant)
- Destination : MySQL ou PostgreSQL
- Mode : chargement complet (full refresh)

Techniquement :

- 1 table Bronze = 1 source CSV
- Aucune correction métier
- Historique conservé

Exemples :

- *bronze_beneficiaire*
- *bronze_adhesion_detail*

Couche Silver : les Données nettoyées et conformes

L'objectif de la couche **SILVER** est de produire des données fiables et cohérentes. Les transformations Silver doivent être réalisées en SQL, via **DBT**.

Transformations attendues :

- Normalisation des valeurs (ex : H/M → Homme/Femme)
- Typage des colonnes
- Suppression ou isolement des données erronées

- Règles métier simples

Couche Gold : les Données analytiques

L'objectif de la couche GOLD est de fournir des tables prêtes pour l'analyse décisionnelle aussi en SQL, via **DBT**.

Cela implique :

- La modélisation en schéma en étoile
- La création de tables de dimensions et d'une table de faits
- La possibilité de créer, si nécessaire, des tables d'agrégats afin de répondre efficacement à des indicateurs clés de performance (KPI)

Les tables GOLD doivent être conçues pour faciliter :

- Les analyses multidimensionnelles
- Les calculs d'indicateurs
- Les requêtes analytiques par les outils de reporting BI

Exemples :

- **Tables de dimensions** : BeneficiaireDim, ActeDim, AgeDim, etc.
- **Table de faits** : SinistreFact
- **Tables d'agrégation (en option)** : Agrégats par période, Agrégats par bénéficiaire, acte ou tranche d'âge. Ce sont souvent des tables dédiées au calcul de KPI récurrents.

b. Gestion de la qualité des données

Vous devrez identifier les données incorrectes (par exemple un sexe manquant ou invalide) et les traiter explicitement. Les données erronées devront soit être isolées dans des tables spécifiques dédiées au suivi des anomalies, soit être corrigées ou exclues des tables analytiques, selon des règles clairement définies. Cette gestion de la qualité des données devra être implémentée **à l'aide de modèles SQL DBT**, en complément des tests de qualité, afin de garantir la traçabilité et la fiabilité des données utilisées pour l'analyse décisionnelle.

Afin de garantir la fiabilité et la cohérence des données produites, **des tests de qualité** des données devront être mis en œuvre à l'aide de **DBT**. Ces tests ont pour objectif de vérifier que les données respectent les règles fonctionnelles et techniques attendues tout au long du pipeline ELT.

Les tests à implémenter incluent notamment des tests de non-nullité, permettant de s'assurer que certaines colonnes critiques ne contiennent aucune valeur manquante. Cela concerne en particulier les clés primaires, les clés étrangères, les identifiants et les champs temporels indispensables à l'analyse décisionnelle.

Des tests de valeurs acceptées devront également être définis afin de vérifier que certaines colonnes ne prennent que des valeurs autorisées par les règles métier. Par exemple, la variable sexe devra appartenir à l'ensemble des valeurs autorisées {M, F}, ou à toute autre nomenclature explicitement définie.

Enfin, des tests d'unicité devront être mis en place afin de garantir l'unicité des clés primaires dans les tables de dimensions et dans les tables de faits, condition indispensable à la fiabilité des analyses et des jointures.

L'ensemble de ces tests devra être déclaré dans les fichiers de configuration DBT (*schema.yml*) et exécuté automatiquement lors de l'exécution du pipeline.